

Il crimine urbano: un'analisi spazio-temporale e predittiva del fenomeno

Isabella Bessone¹, Matteo Gabardi², Giulia Grazzi¹, Daniele Lacapra³, Roberta Pollastro³

Sommario

La domanda di ricerca a cui si è voluto rispondere in questo progetto è stata: è possibile, sulla base dei dati forniti dai distretti di polizia della città di Los Angeles, prevedere in quale intervallo di tempo e in che luogo della sua giurisdizione avverranno i prossimi crimini? Dopo aver analizzato alcuni studi che ponevano quesiti simili, si è deciso di considerare il fenomeno dei furti d'appartamento, a causa dell'elevata frequenza riscontrata. Perché lo studio non ignorasse le condizioni socioeconomiche dei *neighborhood*, sono state implementate le tecniche di Machine Learning con l'ausilio di variabili ambientali. È stato inoltre assegnato ad ogni unità spazio-temporale un fattore di rischio creato ad hoc sulla base del numero di furti avvenuti in precedenza in quella stessa area e nelle limitrofe. La previsione che si ottiene dal dataset utilizzato è però inficiata dalla natura della variabile target, la cui classe positiva (presenza del crimine) è fortemente sbilanciata. L'analisi si propone dunque di trovare una soluzione, risolvendo con le metodologie adeguate il problema degli eventi rari. Avendo applicato diverse tecniche di classificazione, attraverso un'attenta comparazione dei metodi, si è giunti ad una soluzione ottimale in grado di fornire risultati soddisfacenti sia in relazione alla performance sia per quanto riguarda l'attendibilità dell'indagine stessa.

Keywords

Machine Learning — Crime Analysis — Imbalanced Class

¹ Università degli Studi di Milano Bicocca, CdLM CLAMSES

² Università degli Studi di Milano Bicocca, CdLM Fisica

³ Università degli Studi di Milano Bicocca, CdLM Data Science

Indice

Introduzione	1
1 Dataset e preprocessing	2
1.1 Dataset: Crime in Los Angeles	2
1.2 Dati ambientali: 2010 Census Data	2
2 Calcolo del fattore di rischio	3
3 Modelli	4
4 Dataset sbilanciato	4
4.1 Equal size sampling e Cost sensitive learning	4
4.2 Valutazione delle performance	4
5 Analisi e risultati	5
5.1 Classificazione con metodo holdout	5
5.2 Classificazione con metodo holdout e equal sampling	5
Feature selection con CfSubsetEval • Feature selection sulla Precision • Feature selection sulla F-measure	
5.3 Analisi dei costi	6
5.4 Adaptive Boosting	7
5.5 Curve ROC e confronto con altri modelli	7
6 Conclusioni	8
Riferimenti bibliografici	8

Introduzione

La rapida urbanizzazione di numerose zone metropolitane nel mondo porta con sé una serie di problematiche e sfide da affrontare: la crescita e la diffusione del crimine urbano è certamente una delle più impellenti [1]. In America, le grandi città accusano una presenza di crimini violenti superiori a circa l'80% rispetto a centri minori e a circa il 300% rispetto alle aree rurali [2]. Per la previsione di eventi criminali sono state sviluppate analisi statistiche e geospaziali, che negli anni sono state implementate e rese più efficaci. Grazie infatti all'aumento della potenza di calcolo, i nuovi modelli sono ora in grado di trattare dataset di grandi dimensioni. Basandosi su tali tecniche, la crime analysis fornisce informazioni sulla struttura e i trend della criminalità, con l'obiettivo di contrastare il fenomeno. Supportato da diverse teorie, il criminologo David Weisburd propone di focalizzare l'attenzione sull'area colpita da reato in rapporto al contesto socioeconomico, al contrario degli approcci comunemente utilizzati che pongono l'attenzione sul profilo criminale [3]. Pertanto, sotto quest'ottica, l'identificazione di quartieri o zone specifiche che registrano alti tassi di criminalità rappresenta uno degli obiettivi primari perseguiti dai dipartimenti di polizia delle grandi città. A tal fine, attraverso la conoscenza delle coordinate geografiche dei crimini accaduti in passato, vengono stilate mappe di densità (come quella mostrata in Figura 1), che possono presentare aree nelle quali è avvenuto un numero di eventi criminosi superiore alla media, gli *hot spot*. Tali *hot spot* vengono individuati o sulla base del giudizio

umano oppure tramite metodi di clustering, permettendo il riconoscimento di aree (cluster) statisticamente rilevanti nel modello spaziale dei dati.




Figura 1. Mappa di densità riguardante i furti d'appartamento avvenuti nella città di Los Angeles tra il 2010 e il 2017.

In alternativa, un altro metodo per l'analisi spaziale è il *Risk Terrain Modelling* (RTM), che considera il rapporto tra i fattori ambientali e la frequenza dei crimini per stimare il rischio di comparsa di nuovi reati. RTM cerca di chiarire le cause della presenza di determinati pattern in una certa giurisdizione, in modo tale da evidenziarne le problematiche sottostanti e proporre conseguenti soluzioni per mitigare il rischio, senza concentrare l'attenzione solamente nello studio degli *hot spot*. Un esempio di questa tecnica può essere la ricerca di un'eventuale correlazione tra il verificarsi di una sparatoria e la vicinanza a luoghi di ritrovo, come bar e discoteche.

Alcune tecniche invece si concentrano sul valutare la probabilità attesa che un crimine accada in una particolare posizione spazio-temporale data la cronologia dei crimini passati. I criminali prendono decisioni razionali sull'opportunità di perpetrare un reato considerando fattori come il luogo, la facilità di colpire il bersaglio e il rischio di essere scoperti. Infatti si è evidenziato come le zone in cui sono già avvenuti furti d'appartamento siano più colpite a causa della loro riscontrata vulnerabilità [4]. Su questa ipotesi si basa il modello di Mohler [5]: partendo dalla trattazione dei fenomeni sismici, secondo cui scosse principali vanno a generare successive scosse a loro volta causa di ulteriori eventi (*Epidemic Type Aftershock Sequences*, ETAS), l'autore illustra in modo analogo il problema dei furti d'appartamento. Mohler implementa il metodo ETAS nel contesto urbano: avvalendosi di una metodologia di stima non parametrica studia la forma della funzione di attivazione spazio-temporale dei furti, che esprime un parametro di rischio.

In questo lavoro, sono stati presi in considerazione i furti d'appartamento avvenuti nella città di Los Angeles a partire dal 2010. Date le suggestioni precedentemente presentate, è stato creato un indice di rischio che si basa sul concetto di vicinanza di un punto nello spazio-tempo ai crimini compiuti nel passato. Più un fattore di rischio è elevato, maggiore sarà la concentrazione di crimini nelle aree limitrofe e nel passato prossimo. Mentre per Mohler il parametro di rischio calcolato rappresenta direttamente la probabilità dell'accadimento di un crimine futuro, in questo progetto, invece, a tale misura vengono affiancati dati relativi al *neighborhood* della zona in esame,

riguardanti gli aspetti demografici, sociali, culturali ed economici. Quindi con l'ausilio di tali attributi, si vuole predire il verificarsi o meno di un furto entro un determinato intervallo spazio-temporale impiegando diverse tecniche di classificazione proprie del Machine Learning, i cui risultati sono stati successivamente confrontati al fine di individuare il modello più performante. L'intento di questa analisi, dunque, è quello di fornire informazioni utili ai dipartimenti di polizia orientate all'ottimizzazione della distribuzione territoriale delle pattuglie in un'ottica di prevenzione dei furti d'appartamento.

1. Dataset e preprocessing

1.1 Dataset: Crime in Los Angeles

La città di Los Angeles rende pubblici i dati riguardanti i reati avvenuti nella propria giurisdizione, aggiornandoli settimanalmente [6]. L'analisi che si intende proporre fa riferimento a 1.584.316 crimini registrati dal 1 gennaio 2010 al 9 settembre 2017. Il dataset contiene indicazioni attinenti alla tipologia del reato, alla sua posizione in termini di latitudine e longitudine e alla data in cui è stato commesso, oltre a dettagli sulle vittime e sul *modus operandi* del criminale. Va tenuto in considerazione che questi dati sono il frutto di un'operazione di trascrizione di report cartacei originali della polizia e possono perciò contenere imprecisioni, omissioni ed errori.

Inizialmente sono state trattate le variabili concernenti la categoria del reato. Sono stati perciò eliminati gli attributi ritenuti ridondanti o poco informativi, mantenendo esclusivamente la descrizione del crimine e il corrispondente codice identificativo. Dal momento che il dataset presenta 138 possibili reati differenti, molti dei quali richiamano la stessa tipologia criminale, si è deciso di raggrupparli seguendo le direttive fornite dall'FBI contenute nell'*Uniform Crime Reporting Handbook* [6], distinguendoli infine in 21 macro-categorie. Tra queste i furti di appartamento, le aggressioni aggravate e i furti d'auto riscontrano il maggior numero di occorrenze.

Per quanto concerne la trattazione dei missing value, si è deciso di eliminare i record che non presentavano il valore del codice del crimine, in quanto non riconducibili a nessuna categoria. Tenendo conto dell'obiettivo prefissato, sono stati ritenuti rilevanti solamente gli attributi relativi alle coordinate spazio-temporali dei crimini e la loro tipologia. I dati riguardanti le vittime e il *modus operandi* non vengono selezionati perché non possono essere implementati sotto le condizioni del modello che verrà realizzato (Sezione 2).

1.2 Dati ambientali: 2010 Census Data

Grazie alla presenza delle coordinate spaziali dei singoli crimini, è stato possibile inserire nel dataset originale informazioni di carattere ambientale attraverso i dati del censimento realizzato negli Stati Uniti nell'anno 2010. Per ogni *neighborhood* di Los Angeles sono state così raccolte variabili attinenti al contesto demografico, sociale ed economico quali densità di popolazione, composizione etnica, reddito mediano annuale, livello di studi, etc. (Appendice: Variabili del dataset). Per associare univocamente ciascun crimine al *neighborhood* in cui è avvenuto, si è ricorso a un software per la trattazione di dati geografici, QGIS, con il quale è stata eseguita un'intersezione tra il layout dei confini dei quartieri e la latitudine e longitudine del reato. I record che non presentavano coordinate geografiche o che




Figura 2. Rappresentazione schematica dei passaggi effettuati: a) lo spazio-tempo è stato suddiviso in celle di uguali dimensioni; b) in una cella possono essere avvenuti crimini (celle rosse) o non esserne avvenuti (celle blu); c) celle in cui sono avvenuti dei crimini; d) per ogni cella, si trovano i primi vicini (tra le celle rosse) considerando solo celle riferite a un tempo passato.

non è stato possibile ricondurre a nessuno specifico *neighborhood* sono stati rimossi.

L'analisi che verrà presentata nelle prossime sezioni si è concentrata sui dati relativi ai crimini avvenuti tra il 2010 e il 2013. In questo modo è stato possibile ottenere una maggiore coerenza dei risultati con i dati del censimento effettuato nel 2010, oltre a una maggiore efficienza dal punto di vista computazionale. Il dataset così ottenuto consta di 1.572.602 istanze e 28 attributi, di cui 24 ambientali (Appendice: Variabili del dataset).

2. Calcolo del fattore di rischio

Partendo dal dataset descritto precedentemente, mediante l'ideazione di un modello, si è voluto estrarre una nuova variabile che riuscisse a riassumere in sé il concetto di vicinanza di ogni punto dello spazio-tempo con i furti d'appartamento precedentemente avvenuti. Per fare questo è stata effettuata una manipolazione dei dati attraverso il software Knime.

Posto che per questo modello non è computazionalmente praticabile trattare lo spazio-tempo come un attributo continuo¹, si è deciso di suddividerlo in un insieme finito di celle di uguali dimensioni, ciascuna delle quali descrive una certa area della città di Los Angeles entro un determinato intervallo temporale (Figura 2a). Il dominio spaziale viene definito da tutte le zone della città nelle quali sia mai accaduto un reato nel dataset analizzato. Non vengono quindi considerate zone fuori dalla giurisdizione cittadina o che, per qualsiasi motivo, non sono mai state colpite da crimini. Il dominio temporale invece si estende dal 1 gennaio 2010 al 9 settembre 2017.

Le dimensioni di tali celle risultano essere un parametro fondamentale in quanto andranno a definire la risoluzione massima entro cui potranno essere effettuate le previsioni. In questo lavoro ogni elemento copre un'area di circa 4 km² e un arco di tempo pari a un giorno. Questa scelta, frutto di diverse prove, è dettata da limiti di calcolo.

È stato quindi creato un nuovo dataset dove ad ogni record corrisponde una e una sola cella. Complessivamente le righe definiscono l'intero volume spazio-temporale che viene esaminato.

In ogni record/cella possono essere capitati zero, uno o più furti d'appartamento (Figura 2b). Si è quindi aggiunta una nuova variabile

binaria, CRIME OCCURRED, che descrive la presenza (1) o l'assenza (0) di tale reato e che verrà trattata come variabile di output nei modelli di classificazione. Ogni cella inoltre eredita gli attributi ambientali dal *neighborhood* a cui appartiene. Nel caso in cui la cella sia posta in una zona di confine tra *neighborhood*, l'eventuale conflitto viene risolto scegliendo la mediana degli attributi di tutti i furti avvenuti nell'area della città sottesa dalla cella. Gli attributi specifici del crimine (dati sulle vittime, arma utilizzata, etc.) non possono invece essere impiegati in quanto non inerenti alla cella, che è un volume spazio-temporale, motivo per la quale sono stati precedentemente filtrati (Sezione 1).

Una volta create tutte le celle, i valori di latitudine, longitudine e tempo sono stati normalizzati. Questo passaggio risulta essere delicato. Se è lecito infatti supporre che il peso relativo delle due coordinate spaziali sia il medesimo, non vale lo stesso per il tempo in relazione allo spazio: un crimine verificatosi tempo addietro in una zona immediatamente vicina a quella in esame potrebbe essere più influente di un crimine avvenuto a molti isolati di distanza il giorno prima, e viceversa. Si è deciso di effettuare una normalizzazione nell'intervallo [0,1] per tutte e tre le coordinate spazio-temporali, con la consapevolezza che un approccio differente possa portare a risultati diversi del fattore di rischio.

In seguito, per ogni cella sono state trovate le celle più vicine nelle quali sono occorsi crimini in un tempo ad essa passato² (Figura 2d). L'algoritmo implementato in Knime è stato impostato per individuare al massimo 50 vicini per ogni record e comunque non più distanti di 75 giorni. Queste condizioni sono state stabilite per limitare il costo computazionale.

Sono state quindi calcolate le distanze temporali, t , e spaziali, d , di ogni cella dai propri vicini applicando la metrica euclidea. Servendosi della funzione per l'analisi di pattern criminali di cui si sono avvalsi Bowers et al. [7], si è ricavato il fattore di rischio:

$$f_{rischio} = \sum_{k=1}^N \frac{n_k}{(1+t_k)(1+d_k)} \quad (1)$$

dove k è l'indice che individua il vicino, N è il numero di vicini e n_k è il numero di furti accaduti nel vicino k -esimo. Dalla funzione utilizzata deriva necessariamente che il fattore di rischio sarà tanto più elevato quanto più una cella è prossima nel tempo e nello spazio

¹ Sarebbe necessario in tal caso utilizzare un numero infinito di record

² In questo modo i crimini futuri non influiranno sul fattore di rischio invertendo il rapporto tra causa e conseguenza

a furti avvenuti nel suo passato, ovvero ai vicini.

Tale fattore di rischio non va considerato né come un valore assoluto, in quanto è relativo al sistema analizzato, né come una probabilità intrinseca dell'accadimento di un crimine nella cella, ma come un attributo estratto che si propone di essere maggiormente informativo delle singole coordinate spazio-temporali delle celle. È opportuno evidenziare che, se tale fattore deve essere calcolato in una cella, sono necessarie quante più informazioni spazio-temporali possibili riguardo ai crimini avvenuti nell'immediato passato della stessa. Esso viene usato congiuntamente alle variabili ambientali nei modelli di classificazione.

3. Modelli

In questo lavoro sono state applicate diverse tecniche di classificazione inerenti il Machine Learning per fornire agli agenti di polizia risposte circa i fenomeni criminali, con l'obiettivo di individuare la tecnica più adatta sulla base dei dati disponibili:

- **Modelli probabilistici:** tra i metodi più utilizzati vi sono quelli basati su ipotesi probabilistiche come il classificatore Naive Bayes e AIDE, che permettono, a partire dall'elevata quantità di dati, di ottenere risultati accurati sotto ipotesi di indipendenza tra gli attributi.
- **Modelli euristici:** nonostante non garantiscano di giungere a risultati ottimali, permettono di ottenere soluzioni approssimate e ragionevoli. Questi metodi fanno riferimento in particolare agli alberi decisionali che vengono sviluppati a partire da un sottoinsieme di dati iniziali (training set) per il quale è nota la classe output. La classificazione avviene sulla base della classe maggioritaria all'interno del nodo finale. Tra questi modelli si è concentrata l'attenzione sul classificatore Random Forest, sull'albero di regressione J48, e sul Naive Bayes Tree.
- **Modelli di regressione:** basati sulla regressione logistica, il loro vantaggio è rappresentato dalla possibilità di considerare qualsiasi tipo di input, risultando così estremamente flessibili. Dopo aver individuato la risposta, CRIME OCCURRED, e gli attributi input, il metodo intende misurare l'effetto di ciascun input sull'output e la risposta sarà identificata in merito al valore assunto dagli input che la influenzano maggiormente.
- **Artificial neural network:** si basano sulla raccolta di unità o nodi collegati tra loro e chiamati neuroni artificiali, che una volta ricevuto ed elaborato il segnale lo inviano ai neuroni ad essi collegati. Tra i classificatori appartenenti a questa categoria di algoritmi è stato utilizzato il Multilayer Perceptron, che si serve della tecnica di *backward propagation error* per classificare le istanze.

4. Dataset sbilanciato

Il dataset presenta una distribuzione non equa tra le modalità della variabile risposta, squilibrio che può interferire nei risultati prodotti dai classificatori usati. Si è infatti riscontrato che utilizzare modelli di classificazione, sia parametrici che non, basati su dataset sbilanciati comporta un'alta Accuracy per gli eventi più frequenti e una bassa Accuracy per gli eventi rari. L'Accuracy è data dalla formula:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2)$$

dove:

- *TP* e *TN* rappresentano il numero di istanze appartenenti rispettivamente alla classe positiva e negativa classificate correttamente;
- *FP* e *FN* indicano il numero di istanze (negative e positive) classificate erroneamente.

Diventa quindi opportuno servirsi di altre misure di valutazione e applicare modelli di classificazione maggiormente predisposti a considerare il problema di imbalanced class. Nel corso dell'analisi la variabile target CRIME OCCURRED è fortemente sbilanciata, con una minoranza della classe positiva (*I*) rappresentata da solo circa lo 0.9% del totale. La mera applicazione di algoritmi di classificazione, come avvalorato dalla letteratura [8], si è rivelata deludente dal punto di vista della performance, in quanto il modello tende a concentrarsi maggiormente sulla classe frequente, ignorando la classe rara.

4.1 Equal size sampling e Cost sensitive learning

Nel progetto sono stati applicati due approcci: il ricampionamento tramite l'equal size sampling e il cost sensitive learning. La prima è una tecnica di random undersampling, secondo cui si campionano in modo casuale le osservazioni della classe maggioritaria, in modo tale da ottenere come risultato finale un dataset costituito dalla stessa proporzione di eventi rari ed eventi frequenti. Tale metodo solleva tuttavia delle problematiche legate all'eliminazione di dati che si potrebbero rivelare utili nel processo di classificazione.

Il secondo metodo, ovvero il cost sensitive learning, fa riferimento alla matrice dei costi in relazione alla matrice di confusione. Quest'ultima descrive la performance del classificatore tenendo conto sia del numero di osservazioni classificate correttamente (*TP*, *TN*) sia di quelle classificate in modo errato (*FP*, *FN*) [9]. Il classificatore apprende basandosi sulla matrice dei costi, che associa ad ogni istanza di quella di confusione uno specifico peso.

4.2 Valutazione delle performance

Come è stato precedentemente spiegato, l'utilizzo dell'Accuracy come misura per valutare la bontà del classificatore non è il metodo più adatto nel caso di dati sbilanciati. Per tale motivo vengono presi in considerazione altri criteri in grado di dare una migliore e più completa valutazione della performance. In particolare si è scelto di calcolare Recall, Precision, F-measure e Area Under Curve (AUC) della curva Receiver Operating Characteristic (ROC).

La Recall viene anche definita True Positive Rate:

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

Rappresenta la porzione di record positivi correttamente classificati dal modello. Un alto valore di Recall indica una bassa percentuale di

record positivi classificati in modo errato.

La Precision, invece, descrive la frazione di record che sono effettivamente positivi tra tutti quelli predetti come tali:

$$Precision = \frac{TP}{TP + FP} \quad (4)$$

Maggiore è la Precision minore sarà il numero dei falsi positivi.

In alcuni casi queste due misure possono essere in conflitto: all'aumentare dei true positive della classe rara si determina un conseguente miglioramento della Recall, ma al contempo ciò comporta un peggioramento della Precision in quanto potrebbe aumentare il numero dei falsi positivi. Per evitare tale effetto vengono vagliate misure alternative che integrano questi due criteri di valutazione, come la F-measure: una media armonica tra la Recall e la Precision che assume valori nell'intervallo $[0, 1]$ ³:

$$F - measure = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall} \quad (5)$$

Un ulteriore metodo per valutare il modello di classificazione senza però tener conto della distribuzione delle classi e della matrice dei costi è la rappresentazione della curva ROC, che mette in relazione la percentuale di falsi positivi con quella di veri positivi. Una volta ottenuta la curva è possibile calcolare l'area sottesa al grafico (AUC), che assume un ruolo centrale come misura di performance.

5. Analisi e risultati

L'obiettivo principale dell'analisi effettuata consiste nella previsione dell'occorrenza di un furto d'appartamento in una determinata area della città di Los Angeles e in uno specifico intervallo temporale. A partire dal dataset creato (Sezione 1) e dallo studio del dominio spazio-temporale (Sezione 2) è stato possibile individuare la variabile risposta CRIME OCCURRED, indicatrice della presenza o meno di tali furti. Al fine di applicare i metodi di classificazione sono state individuate le seguenti variabili di input: il fattore di rischio, le componenti ambientali e le coordinate spazio-temporali.

Di seguito vengono affrontati nel dettaglio i diversi approcci impiegati nella classificazione.

5.1 Classificazione con metodo holdout

Nella prima fase dell'analisi è stato suddiviso il dataset in un training set (formato dal 66% dei record) e in un test set (con il restante 34%), come previsto dal metodo holdout. I classificatori sono stati direttamente addestrati con il training set così ottenuto e validati attraverso il test set.

I risultati ottenuti sono mostrati in Tabella 1.

Come è possibile notare tutti i classificatori forniscono un'elevata Accuracy a causa della natura sbilanciata del dataset. Al contrario le misure di performance come la Precision, la F-measure e la AUC presentano valori non soddisfacenti, poiché i classificatori sono portati a classificare le istanze solo negativamente. In particolare:

- Naive Bayes, AIDE e Random Forest classificano la maggior parte dei record come appartenenti alla classe maggioritaria, ovvero l'assenza di crimine (0);

Tabella 1. Classificatori con holdout

Classificatore	Recall	Precision	F-measure	Accuracy	AUC
AIDE	0.055	0.016	0.024	0.961	0.616
Naive Bayes	0.312	0.019	0.036	0.855	0.646
Logistic	0.000	/	/	0.991	0.672
Multilayer Perceptron	0.000	/	/	0.991	0.332
J48	0.000	/	/	0.991	0.500
NBTree	0.000	/	/	0.991	0.602
Random Forest	0.002	0.059	0.005	0.991	0.540

- J48 si comporta come una Zero Rule⁴ e restituisce le osservazioni come tutte appartenenti alla classe negativa.

Considerando questi risultati è stato possibile concludere che i classificatori impiegati non risultano essere in grado di comprendere e dunque interpretare il fenomeno oggetto di studio. Inoltre osservando la AUC per i modelli Naive Bayes Tree, Logistic e Multilayer Perceptron si nota come assumano valori diversi da 0.5. Ciò si può spiegare tenendo in considerazione che per la realizzazione della curva ROC vengono utilizzate le probabilità della variabile output.

Si è deciso in seguito di accompagnare tali metodi con tecniche basate sul campionamento. Si cerca così di ridurre le alterazioni portate dalla presenza di imbalanced class all'interno del dataset.

5.2 Classificazione con metodo holdout e equal sampling

5.2.1 Feature selection con CfSubsetEval

Dopo aver suddiviso il dataset iniziale in test set e training set, si è deciso di applicare solo a quest'ultimo un campionamento di tipo equal size sampling (Sezione 4). Si è potuta applicare questa tecnica di undersampling nonostante il forte sbilanciamento, in quanto le istanze della classe minoritaria risultano numerose (132.754 su un totale di 15.335.420). Inoltre attraverso il metodo CfsSubsetEval del nodo Weka AttributeSelectedClassifier è stata ridotta la dimensionalità del training set effettuando una valutazione dei singoli attributi prima di sottoporli al classificatore. In questo modo vengono selezionate le feature che maggiormente influenzano la variabile risposta senza trascurare la correlazione tra le stesse. Il metodo ha individuato come variabili ottimali: FATTORE DI RISCHIO e POPULATION PER SQMI, ovvero la densità di popolazione.

Nella Tabella 2 sono riassunte le misure di performance corrispondenti a questo approccio. Al contrario delle metodologie precedenti, si ha un riscontro per quanto riguarda la classe minoritaria che compare nell'output dell'inducer anche dei modelli euristici.

Tabella 2. Equal Sampling con CfSubsetEval

Classificatore	Recall	Precision	F-measure	Accuracy	AUC
AIDE	0.647	0.015	0.029	0.629	0.692
Naive Bayes	0.410	0.015	0.028	0.758	0.633
Logistic	0.533	0.014	0.026	0.661	0.638
Multilayer Perceptron	0.818	0.011	0.021	0.341	0.362
J48	0.654	0.015	0.029	0.624	0.674
NBTree	0.631	0.015	0.029	0.634	0.685
Random Forest	0.545	0.012	0.024	0.619	0.617

In particolare:

⁴È il metodo di classificazione più semplice che prevede solamente la categoria di maggioranza

³dove 1 rappresenta massimi valori di Recall e Precision

- tutti i classificatori sono caratterizzati da un valore di Precision inferiore a 0.2 mentre la F-measure non supera 0.03;
- nonostante il Naive Bayes sia caratterizzato da un'elevata Accuracy (0.758), presenta il valore più basso di Recall (0.410), sintomo di incapacità a classificare la classe minoritaria;
- A1DE risulta avere un valore di Recall pari a 0.647 e la massima AUC registrata, 0.692;
- nel Multilayer Perceptron si ottengono i valori massimi di Recall (0.818), ma i più bassi di AUC (0.362) e Accuracy (0.341), in quanto tende a classificare positivamente le istanze in modo eccessivo.

5.2.2 Feature selection sulla Precision

Successivamente si è deciso di utilizzare un criterio diverso dal Cfs-SubsetEval per selezionare gli attributi e diminuire la dimensionalità, il metodo wrapper. Si tratta di una tecnica che, mediante un classificatore, ricerca l'insieme ottimale degli input al fine di massimizzare una misura di performance prefissata, in questo caso la Precision. Per ogni modello di classificazione impiegato si è adoperato un wrapper basato sul medesimo classificatore e impostato in modalità *backward*: partendo dall'insieme di tutte le variabili, l'algoritmo ad ogni ciclo filtra un attributo. È stato di nuovo adoperato il metodo holdout grazie al quale è stato possibile suddividere in training set (66%) e test set (34%), di cui solo il 10% è stato fornito al wrapper a causa del costo computazionale del metodo.

Tabella 3. Equal Sampling con ottimizzazione Precision

Classificatore	Recall	Precision	F-measure	Accuracy	AUC
A1DE	0.675	0.015	0.029	0.611	0.695
Naive Bayes	0.459	0.016	0.031	0.753	0.645
Logistic	0.607	0.015	0.029	0.643	0.670
Multilayer Perceptron	0.066	0.012	0.021	0.948	0.317
J48	0.723	0.019	0.037	0.671	0.754
NBTree	0.671	0.015	0.029	0.608	0.688
Random Forest	0.726	0.018	0.035	0.657	0.760

Come si può osservare dalla Tabella 3:

- per tutti i classificatori AUC e Precision assumono valori più elevati rispetto la precedente feature selection con CfsSubsetEval;
- Random Forest per Recall (0.726) e AUC (0.760) assume i valori più elevati, motivo per il quale è stato riconosciuto come il modello più esplicativo in questa fase del lavoro;
- Multilayer Perceptron invece presenta l'Accuracy più alta ma Precision, F-measure e AUC più basse, in quanto tende a classificare in modo peggiore la classe minoritaria.

5.2.3 Feature selection sulla F-measure

Mantenendo l'impianto metodologico presentato nella Sezione 5.2.2, ma configurando il wrapper in modo tale da massimizzare il valore della F-measure, sono stati ottenuti i risultati in Tabella 4.

In particolare il classificatore A1DE risulta essere l'unico che migliora il valore di AUC rispetto a quanto ottenuto con la feature selection basata sull'ottimizzazione della Precision. Gli altri metodi invece sembrano restare invariati o registrare valori delle misure di performance tendenzialmente peggiori.

Tabella 4. Equal Sampling con ottimizzazione F-measure

Classificatore	Recall	Precision	F-measure	Accuracy	AUC
A1DE	0.712	0.015	0.029	0.587	0.703
Naive Bayes	0.653	0.012	0.024	0.542	0.645
Logistic	0.618	0.014	0.028	0.627	0.666
Multilayer Perceptron	0.000	/	/	0.991	0.315
J48	0.718	0.018	0.035	0.655	0.736
NBTree	0.674	0.014	0.028	0.594	0.684
Random Forest	0.696	0.016	0.031	0.618	0.715

5.3 Analisi dei costi

Il secondo metodo valutato per ovviare il problema del dataset sbilanciato è stato l'analisi dei costi. Per fare questo si è adoperato il nodo Weka CostSensitiveClassifier che si basa su approccio Cost Sensitive Learning. Si è fatto uso del 3-folds cross validation, che divide in tre parti il dataset, ognuna delle quali viene usata due volte come training set e una volta come test set. Al termine del processo le misure che si ottengono sono la media delle tre classificazioni effettuate. Per scegliere la matrice di costo da utilizzare sono stati fatti variare in maniera brute force, per ogni modello di classificazione adoperato, i costi dei true positive e dei false positive in un ciclo. I parametri di costo che ottimizzano la misura di performance selezionata vengono in seguito adoperati nella matrice del rispettivo classificatore. Nel ciclo viene impiegato solo l'1% del dataset a causa del peso computazionale dell'algoritmo.

Tabella 5. Cost Sensitive Learning con ottimizzazione Precision, F-measure e AUC

Precision					
Classificatore	Recall	Precision	F-measure	Accuracy	AUC
A1DE	0.085	0.020	0.032	0.955	0.602
Naive Bayes	0.508	0.015	0.029	0.709	0.649
Logistic	0.935	0.009	0.019	0.145	0.609
Multilayer Perceptron	0.999	0.009	0.017	0.009	0.351
J48	0.188	0.020	0.037	0.915	0.556
NBTree	0.037	0.018	0.024	0.987	0.570
Random Forest	0.016	0.033	0.021	0.974	0.545
F-measure					
A1DE	0.407	0.016	0.031	0.784	0.646
Naive Bayes	0.510	0.015	0.029	0.704	0.648
Logistic	0.166	0.024	0.041	0.934	0.666
Multilayer Perceptron	0.999	0.009	0.017	0.009	0.619
J48	0.118	0.021	0.035	0.945	0.535
NBTree	0.254	0.018	0.033	0.872	0.614
Random Forest	0.043	0.028	0.034	0.978	0.610
AUC					
A1DE	0.456	0.016	0.031	0.754	0.656
Naive Bayes	0.749	0.015	0.023	0.439	0.650
Logistic	0.994	0.009	0.018	0.048	0.667
Multilayer Perceptron	0.999	0.009	0.017	0.009	0.602
J48	0.158	0.017	0.035	0.924	0.545
NBTree	0.239	0.019	0.035	0.886	0.612
Random Forest	0.043	0.033	0.037	0.981	0.607

In Tabella 5 sono presentati i risultati ottenuti massimizzando Precision, F-measure e AUC. Nel complesso si può notare che:

- A1DE tende ad avere i valori maggiori di AUC, spostandosi da un valore di 0.602 a uno di 0.656;

- Random Forest presenta i valori più alti di Precision;
- J48 è stato identificato come il modello con le più elevate F-measure.

Generalmente con il Cost Sensitive Learning sono stati ottenuti risultati peggiori rispetto a quelli ricavati con l'approccio equal size sampling. Una possibile spiegazione di questo fatto è che l'algoritmo utilizzato non sia stato in grado di identificare con sufficiente accuratezza la matrice di costo ottimale oppure che la mancanza di una feature selection abbia inficiato la buona performance dei classificatori (*curse of dimensionality*).

5.4 Adaptive Boosting

Una volta individuati i modelli migliori in termini di misure di performance, soprattutto AUC e Precision, è stato applicato loro un algoritmo che permette di migliorare la prestazione del modello originale, ottimizzando a favore di quelle istanze classificate in modo errato dai classificatori precedenti. Si tratta del metodo boosting, una classe di algoritmi di apprendimento automatico basati sull'idea che una combinazione di semplici classificatori possa ottenere risultati migliori dei classificatori presi singolarmente.

In questo lavoro si è fatto riferimento all'adaptive boosting e in particolare è stata applicata l'estensione RealAdaBoost, disponibile nella libreria Knime. La tecnica è una generalizzazione del metodo AdaBoost e consente di migliorare rapidamente l'accuratezza di un modello portando a potenziamenti computazionali e numerici che ne facilitano la gestione.

Tabella 6. Classificatori con RealAdaBoost in Equal Sampling

Classificatore	Ottimizzazione	Recall	Precision	F-measure	Accuracy	AUC
J48	F-measure	0.723	0.035	0.035	0.654	0.751
J48	Precision	0.752	0.019	0.038	0.669	0.770
A1DE	Precision	0.675	0.015	0.029	0.611	0.695
Random Forest	F-measure	0.606	0.013	0.025	0.588	0.634
Random Forest	Precision	0.733	0.018	0.036	0.659	0.761

Nella Tabella 6 vengono mostrati i risultati relativi all'applicazione dell'algoritmo sui diversi modelli selezionati, tutti basati sull'equal size sampling. Si vuole sottolineare come il metodo J48 con ottimizzazione sulla Precision attraverso il boosting abbia raggiunto il valore più elevato di AUC tra tutti i classificatori finora analizzati. Tale approccio adoperava le seguenti feature: FATTORE DI RISCHIO, BLACK POPULATION, ASIAN POPULATION, BACHELOR DEGREE, MEDIAN AGE, DIVORCED MALES, DIVORCED FEMALES, NEVER MARRIED MALES, NEVER MARRIED FEMALES, MARRIED FEMALES, POPULATION PER SQMI, MEDIAN INCOME, MILITARY SERVICE IN 1990-1999.

5.5 Curve ROC e confronto con altri modelli

Per valutare la performance dei classificatori binari è stata affrontata l'analisi della curva ROC (Sezione 4.2), effettuando un raffronto tra i modelli ritenuti maggiormente significativi.

In Figura 3 sono presentate le curve riferite ai modelli analizzati nella Sezione 5.4 per permetterne un paragone. Tra questi il J48⁵ risulta essere superiore ai propri competitors.

Si è in seguito verificata la bontà dello studio realizzato in vista di




Figura 3. Curve ROC dei classificatori con RealAdaBoost. In legenda sono indicati i corrispondenti valori di AUC.

un suo possibile impiego nei dipartimenti di polizia considerando in parallelo i risultati ottenuti da Mohler [5], il cui approccio viene già utilizzato con beneficio dalle forze dell'ordine americane [10]. Il dataset che analizza nel suo lavoro è riferito ai furti d'appartamento a Los Angeles dal 2004 al 2005, intervallo temporale differente da quello considerato in questo progetto.




Figura 4. Grafico cumulative gain del classificatore J48 ottimizzato sulla precision a confronto con i risultati ottenuti da Mohler et al. [5].

Ciò considerato, in Figura 4 vengono qualitativamente messi a confronto gli esiti in un grafico che mostra la percentuale di istanze positive correttamente individuate dal modello in funzione della percentuale di record complessivamente presi in esame (*cumulative gain*). Si può notare che il modello descritto in questo progetto raggiunge performance superiori: si registrano infatti percentuali di

⁵nella versione che ottimizza la Precision

TP più elevate rispetto quelle riportate da Mohler quando si vanno ad esaminare più del 3% dei record complessivi. In linea teorica, quindi, pattugliando in maniera efficace il 15% del territorio della città di Los Angeles sarebbe possibile prevenire fino al 50% dei furti d'appartamento.

6. Conclusioni

In questo lavoro si è voluto identificare la tecnica di Machine Learning migliore per la classificazione dell'occorrenza di furti d'appartamento nella città di Los Angeles con l'obiettivo di prevedere i luoghi in cui avverranno i crimini nel prossimo futuro. Con questo proposito sulla base delle coordinate spazio-temporali dei furti è stata estratta una nuova variabile, il fattore di rischio che, insieme agli attributi ambientali tratti dal censimento del 2010, si propone di individuare la variabile binaria CRIME OCCURRED.

Il problema principale che si è tentato di risolvere in questa sede è stato quello delle classi sbilanciate. I metodi di classificazione infatti non hanno ottenuto in un primo momento risultati ottimali, poiché la classe minoritaria del CRIME OCCURRED rappresenta meno dell'1% del totale delle istanze. Tra le soluzioni consigliate dalla letteratura, sono state impiegate la tecnica di campionamento equal size sampling e l'analisi dei costi, a seguito delle quali sono stati riscontrati effettivi miglioramenti in termini di F-measure e AUC. In particolare mediante l'utilizzo dell'equal size sampling sono state ottenute le performance più soddisfacenti, ulteriormente affinate dall'applicazione del boosting RealAdaboost.

Al termine dell'analisi si è potuto osservare come il modello J48 abbia ottenuto le prestazioni migliori. Secondo alcuni studi, l'approccio euristico infatti rispecchia meglio di altri classificatori il procedimento decisionale umano [11] e quindi sarebbe in grado di descrivere in maniera più accurata il processo di scelta dell'obiettivo da parte dei rapinatori.

Al contrario il Multilayer Perceptron non è riuscito a ottenere risultati soddisfacenti: una possibile spiegazione di questo fatto è che non si sia riusciti a trovare la combinazione ottimale dei parametri di configurazione di tale modello e quindi sfruttare al meglio le sue potenzialità. Le feature selezionate dal modello ritenuto più performante (J48, ottimizzazione per la Precision) fanno riferimento alle variabili sociali ed economiche riguardanti lo status familiare degli abitanti di un *neighborhood* così come la densità di popolazione. Si può ipotizzare che la numerosità e le caratteristiche delle persone che risiedono in una certa abitazione abbiano un ruolo determinante nella vulnerabilità dell'edificio stesso. Anche il grado di scolarizzazione e la composizione etnica dei quartieri appaiono influenzare le decisioni del criminale.

Come verifica conclusiva si è scelto di confrontare il modello sviluppato con altri metodi di crime analysis già impiegati sul campo con riscontri positivi. La tecnica sviluppata da Mohler et al. si pone i medesimi obiettivi di ricerca ed è stata anch'essa implementata su un campione di crimini che fa riferimento alla città di Los Angeles. A causa del differente dataset utilizzato non è stato possibile effettuare un'analisi statistica di raffronto, tuttavia un confronto qualitativo dei grafici di *cumulative gains* ha dato un riscontro positivo del modello realizzato in questo lavoro.

Con l'intento di perfezionare l'analisi affrontata in questa sede sono

stati individuati alcuni possibili miglioramenti seguendo i quali sarebbe possibile potenziare la performance dei classificatori utilizzati:

- nell'algoritmo utilizzato per calcolare il fattore di rischio è stata effettuata una normalizzazione nell'intervallo $[0,1]$ sia per lo spazio che per il tempo. Si potrebbe invece considerare le coordinate spazio-temporali con pesi differenti, al fine di migliorare l'efficacia della nuova variabile creata;
- come suggerito da alcuni studi presenti nella letteratura [12], la ricerca di un rapporto ottimale, diverso da quello 1:1 di equal sampling qui sfruttato, può cambiare positivamente i risultati di taluni classificatori;
- le matrici di costo individuate in questo lavoro non sono sembrate in grado di superare il problema dello sbilanciamento delle classi. Esse sono il parametro fondamentale nel Cost Sensitive Learning: lo sviluppo di un algoritmo più valido nell'identificarle può influire sulle performance, così come l'implementazione parallela di una tecnica di feature selection.

Riferimenti bibliografici

- [1] Xing Quan Zhang. The trends, promises and challenges of urbanisation in the world. *Habitat International*, 54:241 – 252, 2016. Housing the Planet: Evolution of Global Housing Policies.
- [2] Edward L. Glaeser and Bruce Sacerdote. Why is there more crime in cities? *Journal of Political Economy*, 107(S6):S225–S258, 1999.
- [3] David Weisburd. Ideas in american policing. *Washington, DC: Police Foundation*, 2008.
- [4] Wim Bernasco and Paul Nieuwbeerta. How do residential burglars select target areas? a new approach to the analysis of criminal location choice. *British Journal of Criminology*, 45(3):296–315, 2004.
- [5] George O. Mohler, Martin B. Short, P. Jeffrey Brantingham, Frederic Paik Schoenberg, and George E. Tita. Self-exciting point process modeling of crime. *Journal of the American Statistical Association*, 106(493):100–108, 2011.
- [6] La crime dataset. <https://data.lacity.org/A-Safe-City/Crime-Data-from-2010-to-Present/y8tr-7khq>.
- [7] Kate J. Bowers, Shane D. Johnson, and Ken Pease. Prospective hot-spotting: The future of crime mapping? *British Journal of Criminology*, 44(5):641–658, 2004.
- [8] Filomena Mauriello. Tecniche di ricampionamento per dataset con classi di risposta sbilanciate. una proposta metodologica per dataset con predittori di natura numerica e categorica. 2014.
- [9] Gary M. Weiss, Kate McCarthy, and Bibi Zabar. Cost-sensitive learning vs. sampling: Which is best for handling unbalanced classes with unequal error costs? *DMIN*, 7:35–41, 2007.
- [10] Walt L. Perry. *Predictive policing: The role of crime forecasting in law enforcement operations*. Rand Corporation, 2013.

- [11] Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An introduction to statistical learning*, volume 112. Springer, 2013.
- [12] Haibo He and Edwardo A. Garcia. Learning from imbalanced data. *IEEE Transactions on knowledge and data engineering*, 21(9):1263–1284, 2009.

Appendice

Variabili del dataset

Al fine di rendere maggiormente chiara la selezione di determinate variabili utilizzate per l'analisi, di seguito viene riportata la lista completa degli attributi selezionati dal dataset originale, degli attributi ambientali implementati tramite l'utilizzo del software QGIS precedentemente spiegato e delle variabili create tramite il trattamento dei dati spazio temporali.

Dataset: Crime in Los Angeles

DATA TIME OCCURRED: Data e ora in cui è avvenuto Il crimine. Le date riportate sono dal 1 gennaio 2010 al 9 settembre 2017.

CRIME CODE DESCRIPTION NEW: Rappresenta la categoria del crimine di riferimento, opportunamente aggregata utilizzando la classificazione dei crimini riportata nell'Uniform Crime Reporting Handbook redatta dall'FBI. Si riporta all'appendice 2 per ulteriori chiarimenti.

LATITUDE: Coordinata geografica estratta dall'attributo originale "Location" composto da latitudine e longitudine.

LONGITUDE: Coordinata geografica estratta dall'attributo "Location".

Dati ambientali: 2010 Census Data

NEIGHBORHOOD: quartieri di Los Angeles.

WHITE POPULATION: Percentuale della popolazione bianca per ogni quartiere.

BLACK POPULATION: Percentuale della popolazione di colore per ogni quartiere.

ASIAN POPULATION: Percentuale della popolazione asiatica.

LATINO POPULATION: Percentuale della popolazione latina.

MEDIAN INCOME \$: Valore mediano del reddito in dollari.

LESS THAN HIGH SCHOOL %: Percentuale di persone con un livello di istruzione inferiore alla scuola superiore.

SOME COLLEGE %: Percentuale di persone che frequentano o hanno frequentato il college.

BACHELOR DEGREE: Percentuale di persone con un titolo di laurea triennale.

MASTERS DEGREE OR HIGHER %: Percentuale di persone con titolo di laurea magistrale o maggiore.

AGE 19 TO 34 %: Percentuale della popolazione con età compresa tra i 19 e i 34 anni di età.

AGE 65 AND UP %: Percentuale della popolazione con età uguale o superiore ai 65 anni di età.

RENTERS %: Percentuale di persone in affitto.

MEDIAN AGE: Età mediana.

ETHNIC DIVERSITY INDEX: è la probabilità che due soggetti diversi presi in modo casuale appartengano a etnie diverse.

NEVER MARRIED FEMALES %: Percentuale di nubili.

MARRIED MALES %: Percentuale di celibi.

NEVER MARRIED MALES %: Percentuale di soggetti maschi che non si sono mai sposati.

MARRIED FEMALES %: Percentuale di soggetti femminili che sono sposate.

WIDOWED MALES %: Percentuale di uomini vedovi.

WIDOWED FEMALES %: Percentuale di donne vedove.

DIVORCED MALES %: Percentuale dei soggetti maschi divorziati.

DIVORCED FEMALES %: Percentuale di soggetti femminili che sono divorziati.

POPULATION PER SQMI: Popolazione per miglio quadrato.

MILITARY SERVICE IN 1990-1999 %: Percentuale di persone che hanno prestato servizio militare tra il 1990 e il 1999.

Attributi creati

FATTORE DI RISCHIO: Riassume il concetto di vicinanza di ogni punto dello spazio-tempo con i furti d'appartamento precedentemente avvenuti. Un fattore di rischio sarà tanto più elevato quanto più una cella è prossima nel tempo e nello spazio a furti avvenuti nel suo passato, ossia vicini.

CRIME OCCURED: Variabile target che descrive la presenza (1) o l'assenza (0) dei furti d'appartamento..

TIME DIFFERENCE: Rappresenta la differenza in giorni tra ogni data e la prima data di riferimento, ovvero 1/01/2010.

Classificazione dei crimini

Il dataset originale comprendeva 138 tipologie di crimini, si è deciso di raggrupparle in macro categorie facendo riferimento alla classificazione dei crimini elaborata dall'FBI in *Uniform Crime Reporting Handbook*. In particolare la classificazione comprende la determinazione delle categorie di reato maggiormente gravi e più comunemente segnalate negli Stati Uniti. Sono stati così raggruppati i crimini originali in 21 tipologie:

1. Criminal Homicide
2. Forcible Rape
3. Robbery
4. Aggravated Assault
5. Burglary
6. Larceny-theft (except motor vehicle theft)
7. Motor Vehicle Theft
8. Arson
9. Other Assaults
10. Forgery and Counterfeiting
11. Fraud
12. Embezzlement
13. Vandalism
14. Weapons: Carrying, Possessing, etc.
15. Prostitution and Commercialized Vice